

Agent Lab GitHub 오픈소스 슈퍼샘플 추가 조사

Worker assignments: 30 (22 unique) · Waves: 3 · Excursions: 1 · Sources: 47 (37 GitHub primary + 10 local, 1 web domain) · Verification artifacts: 2 · Elapsed: 33 min

조사일: 2026-08-06

기준선: 이전 보고서의 MCP 2026, ACP, AgentGUI, CWC long-running agents, Open SWE, Attractor, A2UI/MCP Apps, OpenAI Agents SDK/Deep Agents 제외

검증 범위: 공개 GitHub 구현·테스트·README/라이선스, GitHub REST, git ls-remote, Agent Lab 현재 코드/SSOT 대조

판정 단위: 저장소 전체 채택이 아니라 **흡수할 패턴, 통합 실험, 인프라 참고, 관찰, 제외**

결론

추가 조사에서 가장 가치가 큰 것은 새 orchestration framework가 아니었다. Agent Lab은 이미 Human Inbox, worktree merge gate, crash recovery, append-only evidence, checkpoint restore-then-stop, 경량 trace를 갖고 있다. 따라서 외부 저장소의 전체 runtime을 들이는 것보다 다음 네 가지를 작은 패턴으로 흡수하는 편이 효과적이다. [L1L3L5](#)

- OpenHands SDK의 Condensation record:** raw event를 삭제하지 않고 forgotten_event_ids + summary + offset 을 append하여 파생 view만 압축한다. Agent Lab의 장기 Room context에 가장 작은 실험으로 붙일 수 있다. [S1S3](#)
- Cline의 typed event/replay translator:** structured event와 legacy stream을 분리하고, tool call ID를 보존한 history replay를 제공한다. 단, approval controller는 idempotency-expiry가 없어 복제하면 안 된다. [S8S10](#)
- OpenInference/OTel GenAI의 projection vocabulary:** Agent Lab event SSOT를 바꾸지 않고 외부 tracing으로 내보내는 어휘로만 쓴다. masking 기본값이 모두 false라 안전 기본 adapter가 선행돼야 한다. [S12S14](#)
- Inspect-Harbor에서 가져온 eval contract:** agent score와 infrastructure error를 분리하고 limit-sandbox-artifact 를 명시한다. 다만 Room Bench v1은 이 프레임워크들 위에 만들지 말고 Agent Lab mission journal의 native deterministic fixtures로 시작한다. [S4S6L6](#)

Warren, OpenSandbox, Microsoft Agent Framework, Magentic-UI, Chidori 는 좋은 참고 구현이지만 각각 authority, teardown, restore semantics, UI trust, exactly-once에서 Agent Lab 불변과 충돌하거나 미검증 영역이 있어 **조건부 실험** 또는 **watch**가 맞다. [S16S20S22S26S29](#)

1. 선정 기준

후보는 다음 세 gate를 모두 통과해야 active shortlist에 남겼다.

Gate	통과 조건	실패 시
구현	README가 아니라 핵심 source/test anchor가 있음	관찰 또는 제외
유지보수	2026-08-06 기준 비아카이브, 라이선스-HEAD 식별 가능	historical/reject
Agent Lab fit	기존 SSOT를 대체하지 않고 새로운 검증 가능한 가치를 더함	pattern-only 또는 제외

“슈퍼샘플”은 dependency 추천과 동의어가 아니다. 이 보고서에서 **pattern source** 는 코드·테스트 아이디어만 흡수하고, **integration experiment** 는 feature flag/adapter 뒤의 가역적 spike, **watch** 는 구현을 추적하되 도입하지 않는다는 뜻이다.

2. 한눈에 보는 판정

우선	후보	분류	흡수할 최소 단위	하지 않을 것
1	OpenHands software-agent-sdk	pattern source	append-only Condensation record와 replay tests	OpenHands runtime 전체 채택
2	Inspect AI + Harbor	composition	native Room Bench fixture/schema와 Inspect export	Harbor/SWE-bench를 v1 권위 상태로 사용
3	Cline	pattern source	event union, replay translator, done dedupe	approval controller-fire- and-forget ACP 복제
4	OpenInference + OTel GenAI	integration experiment	redacted output projection	event/authorization SSOT 교체
5	Apache Burr	pattern source	typed StateDelta, declared reads/writes	workflow runtime 채택
6	Warren	conditional pattern	event provenance, atomic inbox claim, salvage-before-destroy	legacy origin trust-best-effort teardown 복제
7	OpenSandbox + SWE-ReX	infrastructure experiment	sandbox lifecycle/egress/credential adapter contract	Docker만으로 hostile isolation 주장
8	Microsoft Agent Framework	schema/test reference	request map, graph fingerprint, approval result	scheduler-restore runtime 교체
9	Magentic-UI	UI-only reference	approve/deny/alternative + provenance 표현	UI를 Human gate authority로 사용
10	Chidori	watch	leased run, divergence-checked replay, paused signal	exactly-once 또는 core runtime 채택 주장

상위 순서는 “좋은 프로젝트”의 절대 순위가 아니라 Agent Lab에서 작게 검증할 수 있는 순서다. 모든 active 후보는 2026-08-06 GitHub metadata와 default-branch SHA를 재확인했으며, 활동성은 production readiness의 증거가 아니다. [V1](#)

3. 후보별 구현 근거와 흡수 경계

3.1 OpenHands SDK: raw history를 보존하는 context condensation

Condensation은 삭제 대상 event ID 집합, summary, summary insertion offset, LLM response ID를 기록한다. summary는 파생 view에 동적으로 삽입되며 원본 event tree는 남는다. fork/replay 테스트는 condensation 이후에도 raw event가 유지되고, cache rebuild 실패 시 기존 branch/cache가 보존되는 것을 확인한다. [S1S3](#)

Agent Lab에는 model/version, prompt/input hash, policy version, token usage, summary hash를 추가한 확장 record가 필요하다. 성공 기준은 “replay한 view가 deterministic하며 raw chat.jsonl/mission journal은 바뀌지 않음”, 중단 기준은 tool-call/tool-result pair가 분리되거나 rollback이 원본을 복원하지 못하는 경우다. 연결 seam은 mission journal과 context selection이다. [L6](#)

3.2 Inspect AI + Harbor: eval schema는 흡수하되 native Room Bench로 시작

Inspect의 sample state는 message/token/cost/time/working limit, transcript/events, sandbox, retry/error를 분리한다. Harbor는 artifact upload 실패가 발생해도 verifier reward를 보존하여 agent_score와 infra_status/error를 독립 필드로 취급한다. [S4S6](#)

그러나 Agent Lab은 이미 sequence-schema version-idempotency를 가진 mission journal과 Human Inbox/Oracle authority를 갖는다. v1은 다음 5개 deterministic fixture를 native runner로 실행하는 편이 작고 정확하다. [L2](#)

1. plan approve → execute → merge → Oracle PASS
2. plan reject/revise → approve
3. Oracle FAIL → repair → PASS
4. Human Inbox pause → process restart/replay → consume-once resume
5. torn-tail recovery + 동일 idempotency key 재시도

Inspect는 read-only result exporter로 먼저 붙이고, Harbor/SWE-bench는 나중의 containerized adversarial lane으로 분리한다. 외부 evaluator가 run state나 Human gate를 쓰게 해서는 안 된다.

3.3 Cline: event/replay contract만 가져오기

Cline은 structured AgentEvent가 도착하면 legacy chunk fallback을 억제하고, iteration마다 done dedupe를 초기화하며 더 완전한 terminal event를 선택한다. persisted history를 ACP update로 변환할 때 tool call ID와 completed/failed 상태를 보존하고 synthetic prompts를 걸러낸다. [S8S11](#)

반면 approval controller는 request-level idempotency, timeout, cancellation이 없고 global/per-request auto-approve가 가능하다. ACP forwarding은 done/error/usage를 내보내지 않고 await 없이 전송한다. [S10](#)

Agent Lab에는 event_id, monotonic sequence, approval_request_id, expires_at, decision idempotency key, explicit terminal/error/usage가 추가된 translator fixture만 적합하다. Human Inbox는 계속 유일한 승인 권위다. [L1](#)

3.4 OpenInference + OTel GenAI: redacted projection 전용

OpenInference는 AGENT/TOOL/GUARDRAIL/EVALUATOR span과 parent/trace/session, human/LLM/code annotation을 제공하고, OTel GenAI는 invoke_agent / execute_tool 명칭을 제공한다. [S13](#)

하지만 HIDE_INPUTS, HIDE_OUTPUTS, HIDE_LLM_TOOLS 등 masking 기본값이 모두 false다. permission request/decision, Human Inbox, handoff edge도 표준화하지 않는다. [S12](#)

따라서 기존 trace.jsonl과 runtime events를 canonical로 유지하고, 외부 projection에는 ID·hash·status·schema/policy version만 기본 출력한다. raw prompt, tool args/result, approval text는 명시적 opt-in이 아니면 내보내지 않는다. [L1](#)

3.5 Burr: typed delta를 stale-state 회귀 경계로 사용

Burr의 StateDelta는 reads/writes를 선언하고 serialize/validate/apply 단계를 분리한다. [S15](#) Agent Lab에는 이미 mission event journal이 있으므로 Burr runtime을 들일 이유는 없다. 대신 expected_version, affected keys, idempotency key를 가진 typed delta test를 run.json projection parity와 stale-write 회귀에 적용할 수 있다. [L2](#)

3.6 Warren: lifecycle/recovery 패턴은 좋지만 conditional

Warren은 agent가 terminal authority event를 위조하지 못하도록 origin/carrier/payload를 검증하고, run inbox를 transaction 안에서 sequence 할당 후 unread → claimed로 원자 전환한다. plan-run coordinator와 PR gate는

restart/resume, bounded waiting, transient retry를 명시한다. push 실패 시 rescue ref/bundle을 남긴 후 workspace를 제거하는 salvage-before-destroy도 유용하다. [S16S18S20](#)

두 가지는 그대로 복제하면 안 된다. backward compatibility 때문에 origin이 없는 legacy event를 신뢰하며, teardown 실패가 terminalization을 막지 않아 leaked workspace가 GC까지 남을 수 있다. [S16](#) Agent Lab은 이미 merge lease와 boot reconciliation이 있으므로 Warren 전체를 들이지 말고 `unknown origin = fail closed`, `content-addressed decision/event receipt`, `salvage status`, `teardown acknowledgment test`만 흡수한다. [L4](#)

3.7 OpenSandbox + SWE-ReX: phase-2 sandbox contract 참고

OpenSandbox는 Docker/Kubernetes lifecycle, egress policy, Credential Vault와 gVisor/Kata/Firecracker 선택지를 제공한다. Credential Vault는 real credential을 egress sidecar에 두고 허용된 HTTPS 요청에만 header를 주입한다. 다만 DNS-only/default-allow는 우회 가능하고 service mesh와 충돌할 수 있다. [S22S24](#)

SWE-ReX는 Docker/Fargate/Modal backend를 같은 lifecycle interface로 감싼 작은 참고 구현이지만, credential broker, append-only audit, snapshot governance는 제공하지 않는다. [S25](#)

첫 spike는 실제 container가 아니라 fake adapter contract여야 한다: `create`, `immutable repo attach`, `default-deny network`, `scoped credential`, `command stream`, `timeout/cancel`, `destroy-and-verify`, `audit receipt`. 현재 Agent Lab의 `worktree fallback`과 `sandbox policy`를 유지한다. [L8](#)

3.8 Microsoft Agent Framework: checkpoint shape만 참고

Agent Framework는 checkpoint storage/id, pending request/response map, graph fingerprint와 concurrent-run guard를 구현한다. 그러나 restore는 scheduler를 다시 실행하며 superstep 중간 effect는 재실행될 수 있다. tool approval도 auto-approval rule로 우회 가능하다. [S26](#)

Agent Lab에는 request correlation과 graph/schema fingerprint field만 가져오고, checkpoint restore-then-stop과 Human Inbox authority는 바꾸지 않는다. [L3](#)

3.9 Magentic-UI: decision 표현만 참고

Magentic-UI의 `ApprovalDecision`은 `approve/deny/alternative`를, `status/source`는 `user/auto-session/auto-policy` provenance를 구분한다. [S28](#) 이는 Decision Queue 카드 표현에 유용하지만 message metadata는 authorization ledger가 아니다. UI는 immutable request hash에 대한 intent만 보내고 server-side Human Inbox가 actor, expiry, policy hash, decision을 기록해야 한다. [L3](#)

3.10 Chidori: replay conformance watch

Chidori는 active lease가 있는 run의 export를 거부하고 snapshot manifest로 source drift를 감지한다. persisted state는 `Running/Cancelled/Paused/AwaitingApproval`, pending sequence/signal을 포함하며 call replay가 function/args divergence를 검사한다. [S29S31](#)

다만 single-host lease와 journal replay만으로 distributed exactly-once를 증명하지 못한다. 외부 side effect는 idempotency key가 필요하다. 당장은 두 concurrent resume, crash-after-effect-before-journal, source drift, signal consume-once conformance test의 watch source다.

4. Agent Lab 적용 우선순위

순서	최소 실험	비용	정보 이득	성공 기준	중단 기준
1	mission journal → Inspect-compatible read-only export	S	높음	event 순서 ·schema·count 동일, source 무변경	exporter가 state를 쓰거나 정보 손실
2	provenance를 확장한 Condensation record	S/M	높음	raw event 보존, deterministic replay, context 감소	tool pair 손상 또는 rollback 불가
3	OpenInference redacted projection	M	높음	secret/raw args 미 포함, IDs/hash/provenan ce 유지	masking 누락 또는 schema drift silent failure
4	Burr-inspired typed StateDelta fixture	M	높음	stale/out-of-order write 거부, projection parity	새로운 state authority 생성
5	Cline-inspired provider replay fixtures	M	중상	tool IDs·terminal/error·s equence 보존	fire-and-forget 또는 approval bypass 필 요
6	Warren origin/inbox/salvag e conformance	M/L	높음	unknown origin fail-close, consume-once, teardown receipt	Human gate/merge SSOT 중복
7	native Dialogue Room Bench 5 fixtures	M/L	높음	deterministic replay와 agent/infra 결과 분리	외부 runtime이 authoritative state 가 됨
8	OpenSandbox/SWE -ReX fake adapter contract	L	높음	deny-by- default·timeout·des troy 검증	실제 container가 contract보다 먼저 들 어옴

가장 먼저 구현할 세 가지는 모두 read-only/additive다. 이 순서라면 새로운 runtime dependency 없이 현재 event가 충분한지, context compaction이 안전한지, telemetry가 비밀을 흘리지 않는지부터 falsify할 수 있다.

5. Historical·watch·제외 후보

후보	판정	근거
Overstory	historical local-merge reference	2026-05-28 archive, Warren으로 개발 이동; queue claim/reconciliation gap S32
AutoGen	legacy only	upstream가 maintenance mode와 Agent Framework migration을 명시 S33
OpenAI Swarm	historical/educational	upstream가 Agents SDK successor를 명시 S34
Daytona OSS	reject dependency	upstream가 2026-06 이후 OSS 비유지와 private core 이동을 명시 S35
Google AX	watch after resume implementation	controller에 incomplete execution resume TODO가 남음 S36
AutoGPT platform	legal review required	repository 내 Polyform Shield/MIT 혼합 범위 S37
Netflix Conductor	generic historical reference	agent-native contract가 아니고 조사한 HEAD가 2023-12 수준

후보	판정	근거
Continue	narrow MCP/context reference	process-global manager와 단일 authoritative runtime 부적합
Aider	git UX reference	host repo 직접 편집, structured event/HITL authority 부재
Goose	permission/stream fixture reference	permission은 sandbox가 아니며 Agent Lab gate를 대체하지 않음

Overstory의 1차 “좋은 merge 구현” 평가는 archive 확인 후 철회됐다. active lifecycle/recovery 참고는 Warren, local atomic merge는 Agent Lab의 기존 lease-checkpoint-reconciliation이 계속 SSOT다. [L4](#)

6. 제한과 미검증 영역

- 이 문서는 기술적 OSS screen이다. SPDX metadata는 per-file license, NOTICE, trademark, dependency license 를 대신하지 않는다.
- 유지보수·archive·HEAD 상태는 2026-08-06 snapshot이다. unarchived와 최근 push는 maturity나 production readiness의 증거가 아니다. [V1](#)
- SHA-pinned source와 tests를 읽었지만 해당 외부 프로젝트의 test suite를 실행한 것은 아니다. 실행 검증은 GitHub REST와 `git ls-remote` 로 identity/HEAD/license/archive를 교차 확인한 범위다. [V1](#)
- Agent Lab local fit은 조사 시점 현재 worktree 기준이다. 사용자 변경을 포함할 수 있다.
- Warren legacy origin trust, OpenSandbox cleanup/isolation, Chidori distributed exactly-once, Agent Framework effect replay, OpenInference privacy defaults는 해결된 사실이 아니라 명시적 잔여 위험이다.
- GitHub 외의 시장 채택률·성능 benchmark 순위는 이번 요청 범위에 넣지 않았다.

7. 조사 방법과 수렴

- Wave 1: 14개 독립 축에서 runtime, harness, orchestration, sandbox, telemetry, eval, UI, IDE, workflow, memory, policy, worktree, governance, local fit 조사.
- Wave 2: 8개 구현 lead를 source/test 수준으로 재감사하고 19개 repository를 GitHub REST + `git ls-remote` 로 독립 확인.
- Excursion E1: Overstory archive 발견 → upstream successor Warren 조사 → active shortlist 교체.
- Wave 3: 8개 정제 관점에서 순위, 출처, security, eval practicality, 검증 비용, local duplication, governance, claim completeness를 반대 검토.
- 수렴 이유: 모든 actionable lead를 조사·watch·historical-out-of-scope로 disposition했고, 추가 후보가 top-level 판 정이나 실험 순서를 바꾸지 않았다.

세부 원장은 `claim-graph.md`, `intent-diff.md`, `observation-manifest.md`, `verification-economics.md`, `expansion-log.md`, `excursion-log.md` 에 있다.

Sources

- **OpenHands software-agent-sdk @ da6f546...**: [Condensation model/apply](#), [fork/replay tests](#), [cache rollback](#).
- **Inspect AI @ a752313...**: [ActiveSample limits/state](#), [EvalSample events/results](#).
- **Harbor @ 4698544...**: [reward retained across upload error](#), [verifier result parser](#).

- **Cline @ 81cce3d...** : [session event bridge](#), [dedupe tests](#), [approval controller](#), [history replay tests](#).
- **OpenInference @ 8053d84...** / **OTel GenAI @ 4a39b6e...** : [masking configuration](#), [semantic conventions](#), [agent/tool model](#).
- **Apache Burr @ a05875f...** : [StateDelta](#).
- **Warren @ 8eb58af...** : [event provenance](#), [atomic inbox claim](#), [plan-run coordinator](#), [PR merge gate](#), [salvage](#), [destroy gates](#).
- **OpenSandbox @ 47d85df...** / **SWE-ReX @ 5c995c3...** : [architecture](#), [security policy](#), [Credential Vault](#), [runtime backends](#).
- **Microsoft Agent Framework @ 74a1440...** : [restore/run semantics](#), [auto-approval rules](#).
- **Magentic-UI @ d3c9d13...** : [approval decision model](#).
- **Chidori @ 4bd6240...** : [export fencing](#), [persisted states](#), [replay divergence](#).
- **Historical/reject primary notices**: [Overstory archive](#) and [Warren successor](#), [AutoGen maintenance](#), [Swarm successor](#), [Daytona OSS status](#), [AX resume TODO](#), [AutoGPT license scope](#).
- **Agent Lab local evidence**: [runtime events](#), [mission journal](#), [Human Inbox](#), [merge lease](#), [trace recorder](#), [session score](#), [crash recovery](#), [sandbox policy](#), [checkpoint restore](#).
- **Root verification**: [19-repository metadata/HEAD matrix](#) and [Warren follow-up](#).